Bagian A: Analisis Konseptual

1. Efek Regularisasi pada Batch Normalization (Slide 6–8)
   - **Jelaskan mekanisme statistik mini-batch yang menimbulkan efek regularisasi tersebut.**

     Efek regulasi pada batch normalization dapat terjadi karena pemilihan anggota setiap mini-batch akan dilakukan secara acak di setiap epoch. Pada saat training, akan menghitung nilai statistik mean, variance, normalize dan scale-sift pada data dari mini-batch untuk diberikan ke layer selanjutnya (slide 7). Karena anggota dari mini-batch selalu acak, maka perhitungan nilai mean dan variancenya untuk suatu sampel akan terus berubah di setiap epoch. Sehingga dengan ada perubahan nilai ini, pada setiap layer kita akan menambahkan noise pada model. Noise ini akan memberikan efek regulasi. Hal ini dikarenakan dengan adanya noise model akan mempelajari fitur secara lebih umum sehingga model akan terhindar dari overfitting.

     Referensi: https://medium.com/analytics-vidhya/everything-you-need-to-know-about-regularizer-eb477b0c82ba
   - **Uraikan kondisi atau skenario spesifik ketika asumsi "menghilangkan Dropout" ini tidak lagi berlaku atau justru dapat memicu instabilitas pelatihan.**

     Asumsi “menghilangkan dropout” tidak lagi berlaku saat tingkat regularisasi pada batch normalization rendah. Hal ini dikarenakan di batch normalization hanya menimbulkan efek ringan/mild regularization (slide 8). Noise yang terjadi pada batch normalization terjadi karena adanya perubahan nilai statistik mean dan variance mini-batch pada tiap epoch. Saat ukuran mini-batch besar, nilai statistik akan cenderung stabil. Hal ini membuat noise yang dihasilkan akan kecil sehingga model akan overfitting. Sedangkan pada Dropout, overfitting diselesaikan dengan cara mematikan neuron secara acak untuk memberikan noisenya. Noise yang dihasilkan dropout akan lebih banyak karena model tidak belajar dari keseluruhannya. Oleh karena itu, pada saat tertentu batch normalization tetap harus menggunakan dropout untuk menghindari overfitting.

     Referensi: https://learnopencv.com/batch-normalization-and-dropout-as-regularizers/
2. Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)
   - **Mengapa penambahan kedalaman lapisan pada plain CNN (tanpa sambungan residual) justru menurunkan akurasi pelatihan (degradation problem), padahal secara teoritis representasi model yang lebih dalam minimal dapat menyamai model dangkal via fungsi identitas (identity mapping)?**

     Secara teoritis, model yang memiliki kedalaman lapisan yang lebih banyak seharusnya minimal dapat menyamai performa dari model dangkal. Akan tetapi pada plain CNN, akurasi model akan menurun (degradarion problem). Hal ini dikarenakan pada plain CNN setiap lapisan diharuskan untuk mengolah data

dengan sebuah equation matematika. Jika model ingin mengeluarkan output yang sama dengan input maka model harus mencari kombinasi equationnya yang sama persis, dimana akan sulit dilakukan. Selain itu, saat menambahkan kedalaman jalur proses backproparation akan semakin panjang. Hal ini menyebabkan gradient vanishing atau explosion antar layernya sehingga membuat layer-layer awal akan kehilangan informasi gradien yang efektif untuk memperbaharui bobotnya (slide 10).

- **Jelaskan bagaimana skip connection mengubah formulasi aliran gradien saat propagasi balik (backpropagation).**

  Pada skip connection formula backpropagationnya diubah menjadi input x dijumlahkan dengan output beberapa layer (f(x) + x = y) (slide 11). Hal ini membuat layer tidak dipaksa untuk mencari equation dari nol tetapi hanya perlu mempelajari perubahannya saja. Saat backpropagration, skip connection akan lebih sederhana dibandingkan dengan tanpa skip connection. Proses backpropragtion tanpa skip connection akan menghitung gradiennya atau turunananya dengan mengunkan perkalian chain rule. Jika kedalamanya semakin banyak maka chain rule tersebut akan semakin panjang dan rumit. Sedangkan pada backpropagration dengan skip connection chain rule tersebut lebih sederhana karena formula dari chain rule merupakan linear, sehingga untuk menghitung gradientnnya akan lebih mudah.

- **Hubungkan mekanisme tersebut dengan mitigasi fenomena vanishing gradient yang telah dibahas pada Sesi 02**

  Fenomena vanishing gradient dapat terjadi karena proses backpropagation pada layer yang banyak. Pada backpropagation, computer akan menghitung turunan dari fungsi loss terhadap bobot di setiap layer menggunakan chain rule. Jika gradiennya dikalikan dengan angka kurang dari 1, maka nilai gradient tersebut akan mendakti 0 (vanishing gradient). Dengan melakukan skip connection, perhitungan chain rule berubah dari perkalian menjadi bentuk penjumlahan. Hal ini dikarenakan formula dari skip connection terdapat +x sehingga saat diturunkan menjadi +1. Ankga +1 ini akan memastikan bahwa perhitungannya dilayer awal tidak akan sangat kecil atau mendekati angka 0. Oleh karena itu, skip connection dapat mencegah terjadinya vanishing gradient.

3. **Bandingkan pendekatan Feature Extraction (membekukan backbone) dengan FineTuning (membuka sebagian atau seluruh lapisan) ditinjau dari empat dimensi:**
   - **Jumlah parameter yang diperbarui (trainable parameters).**
   - **Kebutuhan volume data latih.**
   - **Beban komputasi dan memori per epoch.**
   - **Risiko rusaknya fitur representasi bawaan (destructive gradient updates).**

	Feature Extraction	Fine Tuning

Jumlah parameter yang diperbarui	Hanya final layer yang diperbarui, sisanya akan di frozen	Banyak karena parameter yang diperbarui dapat semuanya atau hanya spesifik layer
Kebutuhan volume data latih.	Dapat bekerja dengan jumlah data yang sedikit	Membutuhkan jumlah data yang lebih banyak
Beban komputasi dan memori per epoch.	Lebih murah karena hanya train final layer	Lebih mahal karena retraining lebih banyak layer
Risiko rusaknya fitur representasi bawaan (destructive gradient updates).	Tidak terjadi karena selain final layer, layernya akan di frozen sehingga informasinya akan tetap ada	Dapat terjadi karena memperbarui banyak layer sehingga dapat terjadi informasi lama yang berguna ikut terhadus

Referensi: https://www.geeksforgeeks.org/machine-learning/what-is-the-difference-between-fine-tuning-and-transfer-learning/

- **Sintesiskan kriteria praktis kapan masing-masing pendekatan paling tepat dipilih.**
  Feature extraction dapat dipilih saat dataset training yang dimiliki terbatas untuk menghindari overfitting. Hal ini dikarenakan feature extraction hanya train final layer dan freeze layer lainnya. Selain itu feature extraction juga dapat digunakan saat data target yang dimiliki memiliki karakteristik yang mirip dengan dataset pre-training. Pendekatan ini efektif karena model tidak perlu lagi mempelajari karakteristik dasar dari nol pada bagian backbone-nya, sehingga dapat menghemat waktu dan beban komputasi. Sedangkan fine tuning dapat digunakan saat memiliki dataset training yang cukup banyak dan karakteristik targetnya berbeda jauh dengan dataset pre-training. Dengan fine tuning, model dapat mengeksplor untuk menyesuaikan bobot dari setiap layer untuk mengenali patern yang lebih spesifik.

4. Kaidah penerapan data augmentation
   - **Jelaskan pertimbangan metodologis mengapa pipeline data augmentation hanya diaktifkan pada train set dan harus dinonaktifkan pada validation/test set.**
     Data augmentation hanya diaktifkan pada train set untuk memberikan variasi dan keacakan pada data, seperti diberi filer, flip, rotation, crop dan zoom. Hal ini dilakukan agar model dapat tetap mengenali pola meskipun posisi atau bentuknya berubah atau tidak sama dengan train set. Dengan adanya augmentation di train set, kita dapat menghindari overfitting karena model tidak hanya menghafal tapi menangkap karakteristiknya. Sedangkan, saat validation atau test set data augmentation harus dinonaktifkan karena valdation atau test set digunakan untuk mensimulasikan data yang akan dihadapi di dunia nyata. Selain itu, pada saat validation atau test kita ingin melihat seberapa akurat dan bagaimana performa model tersebut dalam mengenali patern yang ada.

- **Berikan satu contoh teknik transformasi citra yang tidak layak digunakan untuk klasifikasi ras hewan peliharaan (pet breeds), dan jelaskan argumentasi ketidaklayakannya berdasarkan invariansi semantik label.**
  Salah satu contoh teknik transformasi yang tidak layak digunakan adalah merubah warna dengan terlalu ektrem. Teknik ini tidak dapat digunakan karena dapat merubah atau merusak karakteristik dari suatu label. Dengan melakukan teknik tersebut, citra tersebut dapat kehilangan informasi penting untuk mengklasifikasi ras hewan peliharaan. Hal ini dikarenakan dalam mengklasifikasikan ras hewan peliharaan, kita memerlukan informasi dari warna bulu atau pola dari bulu hewan tersebut. Jika warna tersebut dihilangkan, maka model dapat kehilangan petunjuk visual utamanya. Akibatnya, model akan kehilangan petunjuk visual meskipun secara konseptual objeknya tetap hewan yang sama. Selain itu model juga dapat mengalami kesalahan klasifikasi pada ras hewan yang secara bentuk tubuh atau struktur morfologinya mirip.

5. Mitigasi Catastrophic Forgetting
   - **Uraikan bagaimana fenomena hilangnya representasi bawaan tersebut terjadi.**
     Catastrophic forgetting dapat terjadi karena saat model baru belajar pada layer yang baru, model akan melakukan penyesuaian bobotnya agar optimal untuk tugas yang baru. Akan tetapi karena perubahan ini, model dapat merusak konfigurasi lamanya atau bobotnya menjahui konfigurasi yang optimal untuk tugas yang lama. Selain itu, jika fine-tuned terlalu cepat atau agresif, fenomena ini akan muncul karena model hanya menghitung error berdasarkan tugas barunya. Hal ini terjadi karena model tidak memiliki mekanisme khusus untuk mengingat atau mempertahankan memori lamanya. Akibatnya, model hanya akan berforkus untuk meminimalkan error pada tugas saat ini dan informasi yang lama perlahan-lahan terhapus dari memori parameter model.
     Referensi: https://www.ibm.com/think/topics/catastrophic-forgetting
   - **Jelaskan dua strategi mitigasi konkret (misalnya differential learning rate, gradual unfreezing, atau linear warmup) beserta alasan teoritis mengapa strategi tersebut efektif.**
     Dua strategi untuk mengatasi fenomena catastrophic forgetting saat melakukan fine-tuning adalah dengan melakukan differential learning rate dan gradual unfreezing. Differential learning rate menerapkan learning rates yang lebih kecil pada layers awal dan learning rate yang lebih besar pada layer selanjutnya. Hal ini dilakukan agar pada layer awal, model hanya belajar low-level featuresnya dan saat layer selanjutnya model akan belajar yang lebih spesifik. Dengan ini, model akan mengadaptasi representasi tingkat tingginya dan melindungi fitur umum dari overwriting bobot awalnya. Gradual unfreezing dapat digunakan sebagai mitigasi karena proses pelatihan dilakukan secara bertahap dari layer atas ke layer bawah. Dengan ini, model tidak akan kehilangan fitur umum karena gradientnya berubah secara perlahan.