Laporan dan Analisis

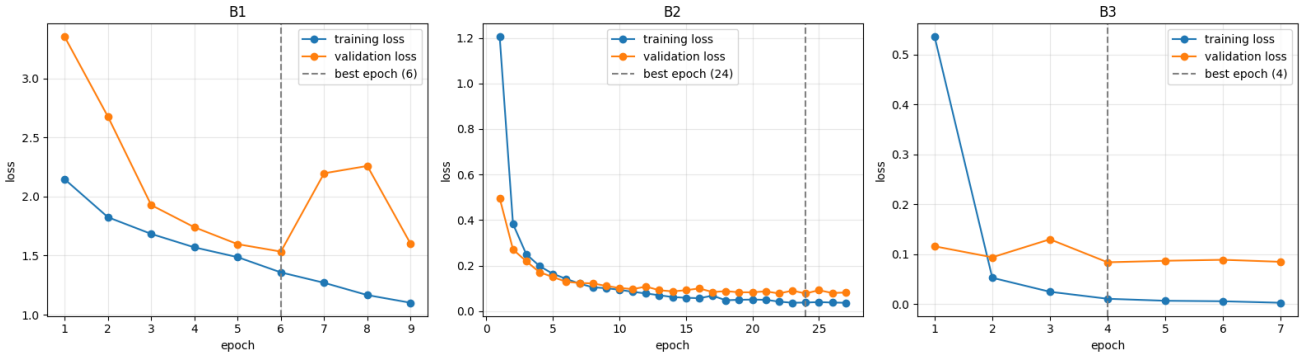
Pada eksperimen dilakukan perbandingan pada 5 strategi pelatihan model ResNet-18 untuk mengklasifikasi 10 ras kucing dan anjing. Dataset yang digunakan adalah Oxford-IIIT Pet yang memiliki 37 kelas ras kucing dan anjing dengan kurang lebih 2000 citra per kelas. Ras kucing yang digunakan adalah Abyssinian, Bengal, Birman, Bombay, dan Persian. Sedangkan ras anjing yang dipilih adalah Beagle, Boxer, Chihuahua, Pug, Samoyed. Eksperimen tersebut dilakukan dengan menggunakan batch size 32, optimizer AdamW (weight decay 1e-2), loss CrossEntropyLoss, early stopping pada validation loss dengan patience 3, dan seed 42.

C1. Tabel Konsolidasi dan Kurva Pembelajaran

Berikut merupakan tabel yang merangkum kondisi B1 hingga B5:

	Strategi	**Trainable Params**	**Learning Rate**	**Epoch Konve-rgen**	**Durasi (s)**	**Val Acc**	**Gap**	**Test Macro F1**
B1	Semua layer dilatih dan model diberi boobt acak	11181642	[0.001]	6	3818.084	0.4916	0.0394	0.4876
B2	Seluruh layer backbone dibekukan dan layer fc dilatih	5130	[0.001]	24	4999.999	0.9798	0.0166	0.9634
B3	layer 4 dan fc dilatih dengan differential learning rate	8398858	[0.0001, 0.001]	4	1663.058	0.9798	0.0202	0.9800
B4	Melatih model B3 tanpa augmentasi (hanya Resize/Crop dan Normalisasi)	8398858	[0.0001, 0.001]	3	1428.836	0.9764	0.0214	0.9765
B4	Melatih model B3 dengan augmentasi (Resize/Crop, Random Horizontal Flip, Random Rotation 15°, dan Color Jitter)	8398858	[0.0001, 0.001]	12	3722.132	0.9697	0.0289	0.9602
B5	Melatih model dari B3 pada arsitektur EfficientNet-B0	1142202	[0.0001, 0.001]	10	2162.399	0.9933	0.0031	0.9796

Berikut merupakan kurva training loss vs validation loss untuk B1, B2, dan B3.



C2. Pembahasan Analisis Komperatif

C2.1. Disparitas Performa antara pelatihan dari nol (B1) dan transfer learning (B2 dan B3)

Disparitas performa dapat ditandai dengan nilai Macro F1. Macro F1 pada pelatihan dari nol (B1) sebesar 0.488 pada test set. Sedangkan B2 memiliki Macro F1 sebesar 0.963 dan B3 sebesar 0.980. Selisih berdasarkan performa macro tersebut sekitar 0.475 dan 0.492. Selain itu, disparitas performa juga dapat dilihat pada validation accuracy dimana B1 sekitar 0.492, B2 dan B3 sekitar 0.9798.

Pada pelatihan dari nol (B1), model mengunakan bobot acak (weight = None) dan memiliki total sebesar 11.181.642 parameter yang harus dilatih. Bobot acak membuat model harus belajar hal-hal umum, seperti garis tepi, bentuk dasar, tekstur, dari nol. Akan tetapi, ukuran dataset yang dimiliki tidak cukup karena hanya memiliki 1.386 citra. Sedangkan pada transfer learning model memakai backbone ResNet-18 pretrained ImageNet (IMAGENET1K_V1) yang merupakan backbone yang sudah dilatih sebelumnya dengan menggunakan dataset yang besar. Hal ini membuat model tidak perlu mempelajari fitur dasar dari awal dan dapat hanya menyesuaikan pada final layer untuk mengenali kategori atau ras hewan dengan spesifik. Dengan menggunakan backbone yang sudah dilatih, starting point model B2 dan B3 akan lebih dekat dengan titik optimal.

Disparitas performa juga disebabkan oleh jumlah parameter yang dilatih dan volume data pada B1 menyebabkan variance tinggi dan kesulitan untuk digeneralisasi. Hal ini dapat dilihat pada pada kurva training loss yang turun stabil dari 2,146 ke 1,101, tetapi validation loss melonjak dari 1,534 pada epoch 6 menjadi 2,197 pada epoch 7. Sedangkan pada B2 dan B3 memiliki pola kurva yang mirip, yaitu training loss yang menurun drastic pada epoch 2 dan stabil seterusnya serta validation loss yang stabil.

C2.1. Trade-off Performa vs. Stabilitas Antara Feature Extraction Murni dan Finetuning

Performa pada Feature Extraction (B2) memiliki hasil validation accuracy sebesar 0.9798 dan Test Macro F1 sebesar 0.9634. Sedangkan pada Finetuning (B3) memiliki validation accuracy yang sama tetapi memiliki Macrio F1 yang lebih tinggi, yaitu 0.9800. Dari hal tersebut performa dari B3 sedikit lebih baik dari B2 pada sisi Test Macro F1. Hal ini dikarenakan pada B2 cenderung lebih mengikuti backboned yang ada sehingga model lebih kesulitan untuk beradaptasi dengan karakteristik yang ada pada dataset. Sedangkan pada B3, karena pada layer tertentu di un-freeze dan menerapkan differential learning rate, model lebih fleksibel untuk menyesuaikan bobot yang ada untuk menyesuaikan dengan karakteristik yang ada pada dataset.

Untuk stabilitas, B2 menunjukkan traning loss yang lebih halus dibandingkan B3. Training loss pada B2 turun bertahap dari 1.204 ke 0.037 dan validation loss turun bertahap dari 0.496 ke sekitar 0.078, tanpa adanya lonjakan. Kestabilan ini terjadi karena backnode pada B2 dibekuka, sehingga proses optinasi hanya berfokus pada final layer yang membuat perubahannya menjadi minimal. Sedangkan pada B3, Validation loss pada epoch 3 mengalami kenaikan pada epoch 3 (dari 0.094 ke 0.130) dan kembali turunpada epoch 4 (0.084). Selain itu, training accuracy pada B3 mencapai 1.000 mulai epoch 4 dan training loss turun hingga 0.003, sementara validation loss mendatar di kisaran 0,084 hingga 0.089. Hal ini menandakan bahwa model mulai menghafal data training atau terjadinya overfitting pada model yang dapat disebabkan oleh model pretrained yang terlalu besar.

C2.3 Peran Augmentasi (B4) dalam Meredam Overfitting

B4 dijalankan pada model B3 dalam dua skenario terpisah dengan seed dan hyperparameter yang sama. Skenario pertama tanpa augmentasi (Resize, CenterCrop, Normalisasi) dan skenario kedua dengan augmentasi (RandomResizedCrop, Random Horizontal Flip, Random Rotation 15°, dan Color Jitter). Data validasi dan test selalu tanpa augmentasi.

Hasil yang didapatkan, model B4 dengan augmentasi tidak dapat meredam overfitting. Hal ini dapat dilihat pada gap training accuracy dan training loss yang melebar dari 0.0214 menjadi 0.0289. Validation accuracy yang didapatkan juga menurun dari 0.9764 menjadi 0.9697. Dan juga, Test Macro F1 juga menurun dari 0.9765 menjadi 0.9602. Selain itu, augmentasi juga memperlambat konvergensi dari epoch 3 menjadi epoch 12. Penurunan performa ini menunjukkan bahwa augmentasi yang diterapkan dapat merusak atau mengubah fitur-fitur utama yang dibutuhkan model untuk mengklasifikasikan ras kucing dan anjing. Hasil ini bertentanggan pada slide 20 yang menyatakan bahwa augmentation dapat menaikan generalisasi terutama pada dataset kecil.

C3. Failure Analysis

Berikut merupakan hasil 8 citra dari test set dengan menngunakan model B3. B3 dipilih dan dianggap paling baik karena memiliki Macro F1 Test tertinggi, yaitu sebesar 0.980.



NO	Label actual	Prediksi (confidence score)	Hipotesis
1	Birman	Persion (0.86)	Ambiguitas visual yang terjadi antara ras berbulu tebal dan berbulu panjang

2	Beagle	Boxer (0.90)	Citra berwarna hitam dan putih sehingga menghilangkan informasi warna dari label actual. Terdapat syal yang menutupi bagian dada dari anjing dan pose kepala yang menghadap ke samping
3	Abyssinian	Bengal (0.88)	Terdapat watermark teks “shutterstock”. Memiliki karakteristik mata yang mirip
4	Boxer	Beagle (0.43)	Subject kecil dan sedang bergerak
5	Abyssinian	Begal (0.49)	Memiliki latar yang terlalu ramai, sehingga memiliki banyak noise
6	Bengal	Abyssinian (0.76)	Bulu tidak telihat terlalu jelas. Pose kucing sedang menyipitkan mata sehingga tidak bisa mengambil karakteristik mata
7	Persian	Persian (0.63)	Memiliki latar yang terlalu kompleks
8	Abyssinian	Abyssinian (0.66)	Wajah tertutup oleh kaki dan pose kucing ekstrem (terbalik)

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

C4.1. Rekomendasi bagi tim rekayasa

Berdasarkan temuan pada eksperimen, rekomendasi bagi rekayasa industry adalah untuk menggunakan strategi fine-tuning (B3). Strategi B3 dipilih menghasilkan Test Macro F1 tertinggi sebesar 0.980. Selain itu, B3 juga dapat menkonvergen secara cepat, yaitu epoch 4. Akan tetapi, training accuracy pada B3 mencapai 1.000 mulai epoch 4 dan training loss turun hingga 0.003, yang menunjukkan bahwa adanya gejala overfitting. Jika tim rekayasa ingin menggunakan strategi B3, tim rekayasa disarankan untuk dapat menangani resiko overfitting tersebut.

Selain itu, tim rekaya tidak disarankan untuk menggunakan pelatihan dari nol (B1) dan tidak menggunakan augmentasi data secara sembarangan (B4 augmentasi). Strategi B1 tidak dianjurkan karena Test Macro F1 sangat kecil, yaitu hanya 0.488. Sedangkan, strategi B4 yang menlakukan augmentasi secara sembarangan tidak disarankan karena B4 memperbesar accuration gap dan menurunkan performa.

C4.2. Keterbatasan Eksperimen

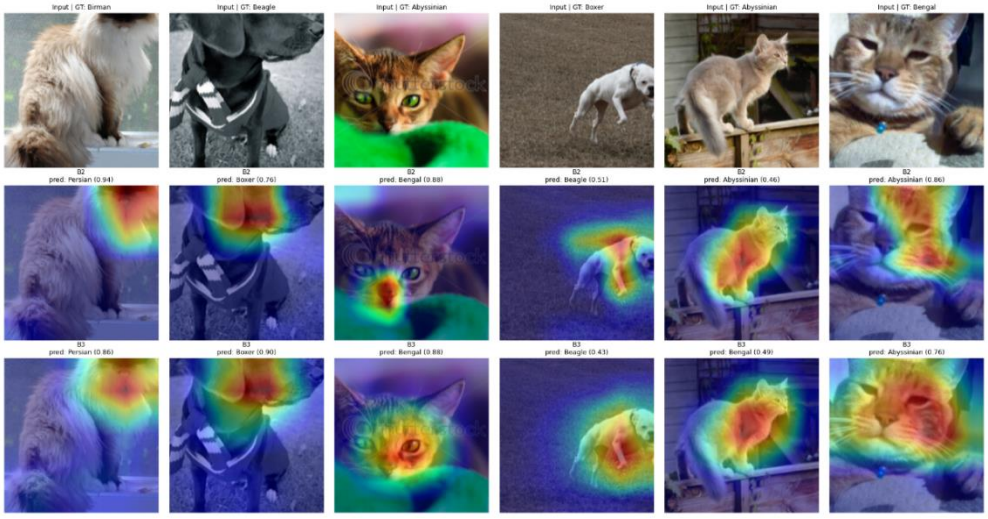
Pada eksperimen ini terdapat beberapa keterbatasan. Pertama, seluruh pengujian dilakukan menggunakan single seed dengan seed 42. Penggunaan single seed menjadi keterbatasan karena dapat berpotensi menciptakan sebuah ilusi bahwa telah sudah akurat dan stabil, padahal performa tersebut hanya sebuah kebetulan saja. Dengan seed dibuat tetap, pembagian data dapat menimbulkan bias-partitioning. Untuk menangangi keterbatasan ini, dapat dilakukan multi-seed cross-validation agar dapat memastikan performa model dan tidak terjadi bias partitioning.

Selanjutnya, ukuran data yang digunakan untuk evaluasi cukup terbatas. Ukuran data yang digunakan untuk memvalidasi model adalah sebesar 297 citra dan untuk testing sebesar 298 citra. Jumlah ini cukup kecil harena model hanya melakukan testing per kelas kurang dari 30 citra. Akibatnya, saat terdapat 1 citra yang diprediksi oleh model salah, maka dapat memberikan penurunan pada score Macro F1.

Selain itu, keterbatasan jumlah kelas juga mempengaruhi model eksperimen. Pada eksperimen ini hanya menggunakan 10 dari 37 ras yang disediakan dataset, dimana terdapat 5 ras kucing dan 5 ras anjing. Dikarenakan 10 kelas tersebut dipilih secara manual, maka kemungkinan terdapat

bias saat melakukan pemilihan. Jika kelas yang terpilih lebih sulit atau mudah dari rata-rata, maka hasil performa model dapat menurun dari rata-rata. Sebagai contoh, model sering tertukar untuk melakukan prediksi pada ras Abyssinian dan Bengal yang sebabkan oleh karakteristik dari ras tersebut mirip yang dapat memengaruhi skor performa model.

C5. Eksplorasi tambahan



Dari Grad-CAM diatas, dapat dilihat bahwa kesalahan klasifikasi yang dilakukan kedua strategi model B2 dan B3 bukan berada pada latar belakangnya. Kedua strategi tersebut telah dapat berfokus pada object yang akan diklasifikasi. Pada B3 heatmap-nya cenderung pada sampel lebih menyebar dibandingkan B2. Pesebaran ini tidak terlalu mempengaruhi perubahan prediksi yang terjadi. Hal ini dapat dilihat bahwa hanya terdapat 1 image dari 6 yang mengalami perubahan prediksi. Hal tersebut dapat mengidikasikan bahwa kesalahan prediksi model bukan karena kesalahan model untuk mengidentifikasi object tetapi kemiripan karakteristik pada ras-ras yang ada.

Pernyataan Penggunaan AI

1. Nama model/alat AI yang digunakan:
   - Claude Sonnet 5.5
   - Gemini
   - ChatGPT
2. Ruang lingkup bantuan AI pada tugas ini:
   - Menjelaskan konsep dan perbedaan antar-kondisi eksperimen (from scratch, feature extraction, fine-tuning, augmentasi) serta kaitannya dengan materi kuliah
   - Memeriksa dan memberi saran perbaikan pada kode yang saya
   - AI tidak digunakan untuk menjalankan eksperimen
3. Cara memverifikasi kebenaran keluaran AI tersebut secara mandiri
   - Penjelasan yang AI berikan saya cocokkan dengan slide kuliah
   - Kode yang di berikan AI saya periksa dan pahami melalui dokumentasi PyTorch dan referensi lainnya yang ada di internet
   - Setiap kode saran AI dijalankan sendiri di notebook dan memerika hasil outputnya sesuai dengan harapan